


Canya



DEEP LEARNING : PROJET DE FIN DE SEMESTRE

MÉTHODE POUR AMÉLIORER LES GANs : **REJECTION SAMPLING**

SOMMAIRE

I) Introduction : Quel est l'objectif ?

II) Discriminator Rejection Sampling (DRS)

- La théorie
- Implémentation des méthodes et résultats
- Interprétation des résultats

III) Conclusion et améliorations possibles du DRS

- Pourquoi le DRS est limité ?
- Améliorations possibles

I) INTRODUCTION


Rappels

Structure du générateur & du discriminateur:


- **Générateur** : 4 couches linéaires successives avec des activations Leaky ReLU pour les couches intermédiaires et tanh en sortie
- **Discriminateur** : 3 couches linéaires successives avec des activations Leaky ReLU pour les couches intermédiaires et sigmoid en sortie

Entraînement : 100 epochs


Métriques d'évaluations : Precision - Recall



$z \sim p_z$
Distribution
latente



$$G(z) \rightarrow p_g(x)$$



But : Atteindre p_{data}
en améliorant p_g
pour approcher au
mieux p_{data} .

Jeu de minimisation de la loss du générateur et de la maximisation de celle du discriminateur :

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log (1 - D(G(z)))]$$

Problèmes ?

1) Qualité des échantillons :


- Certains échantillons $G(z)$ sont de mauvaise qualité.
- Ces échantillons se retrouvent hors de la distribution cible p_{data} .

2) Mode collapse :

- Le générateur peut ignorer certaines parties de p_{data} , réduisant ainsi la diversité des échantillons générés.


3) Rejet d'échantillons inadéquats :

- Besoin d'une méthode pour filtrer les échantillons générés en fonction de leur qualité.



Intuition


- Générer des échantillons à partir d'une distribution simple $q(x)$, puis les filtrer en fonction de leur correspondance avec la distribution cible $p(x)$, grâce au ratio $\frac{p(x)}{q(x)}$
- Ce ratio mesure à quel point un échantillon x généré à partir de $q(x)$ correspond à $p(x)$.
- C'est majoritairement grâce à ce ratio qu'on va déterminer si l'on accepte ou non les échantillons générés.



Rejection Sampling

- Deux hypothèses principales :
 - On peut facilement générer à partir de $\mathbf{g}$
 - $\mathbf{g}$ a le même support que $\mathbf{p}$
- Introduction d'une constante $\mathbf{M}$ tel que :
$$M \cdot g(x) \geq p(x), \forall x$$
- Générer des échantillons à partir de $\mathbf{g}(\mathbf{x})$
- Accepter ces échantillons avec une probabilité de $\frac{p(x)}{M \cdot g(x)}$.

Pourquoi ce ratio ?



Avant de parler du DRS


Limites à prendre en compte :

- Capacité à évaluer $p_{\text{data}}(x)$ en tout point
- Inefficace lorsque la target distribution est concentrée dans une région spécifique (pic), implique un M énorme.

Modification du discriminateur de base :

Suppression d'une couche linéaire : 4 -> 3. De cette façon, le discriminateur généralise mieux en étant moins strict, et évite donc les rejets excessifs et incohérents.

Inefficiency of Rejection Sampling with Concentrated Target Distribution



II) DISCRIMINATOR REJECTION SAMPLING (DRS)

Adaptation de la méthode pour les GANs

Hypothèses :

- Générateur entraîné jusqu'à ce que p_g et p_{data} aient le même support
- On peut compute $\frac{p_{\text{data}}(x)}{p_g(x)}$. Ainsi :

$$M = \max_x \frac{p_{\text{data}}(x)}{p_g(x)}, \quad M \cdot p_g(x) \geq p_{\text{data}}(x), \quad \forall x$$

- On peut optimiser le discriminateur dans l'espace des densités plutôt que changer les paramètres. (Paper Goodfellow et al., 2014).

Implication :

- L'entraînement du discriminateur optimal amène à : $D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$

IMPLÉMENTATION DES DIFFÉRENTES MÉTHODES

Première approche simplifiée


Méthode :

- On récupère le score $D(x)$ du discriminateur qui approche $\frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$


- On choisi M comme étant le max des max des scores sur un nombre de batchs fixé (optionnel ici, car $D(x)$ est déjà une probabilité)
- On crée une probabilité d'acceptation :

$$P_{\text{accept}} = \frac{D(x)}{M}$$

- On accepte chaque sample du générateur une probabilité P_{accept}



Echantillons
acceptés



Echantillons
refusées

Première approche simplifiée


Les résultats :

- **Précision:**
 - Pas de grandes différences visibles sur la qualité, 0.48-0.50
- **Recall:**
 - Légère amélioration


Interprétations :

- **Précision:**
 - Mauvaise implémentation de M, qui est uniquement calculé sur un batch.
 - Probabilité d'acceptation basée uniquement sur $D(x)$.
- **Recall:**
 - Classes sous représentées peuvent être suréchantillonnées avec le DRS, et ont donc un score plus élevé.

Diversité intra classe pour 1



Comparaison des dispersions entre Vanilla et DRS



9	3	1	7	2	2	1	5	6	4	7	2	6	3
0	0	2	9	0	0	9	1	0	5	1	0	4	6
1	4	0	9	8	7	6	9	0	6	9	5	6	5
9	8	4	3	3	2	4	9	3	5	1	1	9	2
3	1	9	7	8	1	9	8	9	7	1	1	8	0
2	5	1	4	0	2	6	7	3	0	7	7	7	2
8	3	0	7	2	4	7	8	3	9	5	8	3	6
1	7	9	1	7	5	8	0	0	4	3	0	3	8
2	1	8	3	7	3	6	6	5	9	2	5	3	1
1	1	5	5	6	2	4	4	2	7	7	5	9	1
6	6	6	6	7	5	1	0	4	5	8	1	6	6
4	1	7	0	3	6	0	2	4	5	4	7	3	9
4	7	3	9	8	2	9	9	7	7	0	5	0	6
1	1	9	5	7	1	1	5	3	7	1	9	1	8

Après DRS

8	3	6	5	9	0	0	0	5	2	3	4	7	5
8	8	0	8	1	1	4	4	3	8	6	2	6	3
7	7	3	4	0	5	2	3	1	4	2	8	4	9
1	3	4	4	7	0	1	2	2	6	8	5	5	6
1	0	3	4	0	0	6	9	1	8	2	9	2	3
0	2	7	9	1	9	1	7	7	6	8	7	1	1
8	2	3	2	0	6	6	7	7	9	8	4	2	5
9	6	4	0	2	9	8	0	3	9	1	6	7	9
1	4	3	3	8	8	1	1	3	6	8	0	5	1
0	1	0	8	3	8	3	5	9	0	0	6	7	6
8	4	0	0	2	1	5	0	2	5	2	3	0	3
0	9	5	5	6	5	7	3	7	9	5	7	9	0
6	0	2	3	9	8	8	5	6	8	1	4	9	4
6	1	4	6	8	4	7	3	0	4	9	1	6	4

Vanilla

Deuxième approche

Méthode :

- Meilleure approche du ratio $\frac{p_{\text{data}}(x)}{p_g(x)}$


En prenant $\frac{D(x)}{1 - D(x)}$, avec $D(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$

$$\frac{D(x)}{1 - D(x)} = \frac{\frac{p_{\text{data}}}{p_{\text{data}} + p_g}}{1 - \frac{p_{\text{data}}}{p_{\text{data}} + p_g}} = \frac{\frac{p_{\text{data}}}{p_{\text{data}} + p_g}}{\frac{p_g}{p_{\text{data}} + p_g}} = \frac{p_{\text{data}}}{p_g}$$


Ainsi, différences entre les deux probabilités amplifiées.

- Adaptation dynamique de M : M recalculé pour chaque batch, pour que P_{accept} soit normalisée en fonction des échantillons du batch courant.

$$P_{\text{accept}} = \frac{p_{\text{data}}}{p_g \cdot M}$$



Echantillons
acceptés



Echantillons
refusées

Deuxième approche


Les résultats :

- **Précision:**
 - Légère amélioration : 0.52-0.53
- **Recall:**
 - Meilleure amélioration que la méthode précédente


Interprétations :

- **Précision:**
 - Le nouveau ratio estimé favorise vraisemblablement plus les échantillons qui trompent efficacement le discriminateur (donc de meilleure qualité).
- **Recall:**
 - Le recalcul de M pour chaque batch assure que les échantillons rares (avec des scores élevés dans leur batch respectif) ont une probabilité raisonnable d'être acceptés.

Diversité intra classe pour 1



Comparaison des dispersions entre Vanilla et DRS



1	9	0	3	2	0	5	4	6	0	2	7	9	5
0	1	6	4	1	8	4	7	4	1	3	1	5	
8	2	5	5	5	7	2	9	8	9	9	1	0	1
9	1	1	4	1	2	9	2	1	0	8	9	0	8
1	1	4	3	3	7	4	6	5	3	1	5	5	6
5	5	6	7	9	6	0	1	8	1	4	5	4	7
5	0	0	6	3	2	1	8	1	8	9	1	0	5
3	0	8	8	2	5	6	3	9	0	2	7	9	0
0	2	0	2	0	4	1	2	7	3	1	0	9	9
3	8	2	6	4	9	0	0	3	4	7	1	1	4
7	8	4	5	1	8	8	0	7	2	8	5	4	2
9	4	2	2	5	2	4	8	3	7	8	8	3	5
2	7	6	9	6	4	6	2	8	7	1	8	3	5
6	1	2	3	9	5	1	0	3	4	4	0	5	7

Après DRS

8	3	6	5	9	0	0	0	5	2	3	4	7	5
8	6	0	8	1	1	4	4	3	8	6	2	6	3
7	7	3	4	0	5	2	3	1	4	2	8	4	9
1	3	4	4	7	0	1	2	2	6	5	5	5	6
1	0	3	4	0	0	6	9	1	8	2	9	2	3
0	2	7	9	1	9	2	7	7	8	8	7	1	1
8	2	3	2	0	6	6	7	7	9	8	4	2	5
9	6	4	0	2	9	8	0	3	9	1	6	7	9
1	4	3	3	8	8	1	1	3	6	8	0	5	1
0	1	0	8	3	8	3	5	9	0	0	6	7	6
8	4	0	0	2	1	5	0	2	5	2	3	0	3
0	9	5	5	6	5	7	3	7	9	5	7	9	0
6	0	2	3	9	8	8	5	6	8	1	4	9	4
5	1	4	6	8	4	7	5	0	4	9	1	6	4

Vanilla

Troisième approche

Intuition :

- Les vecteurs latent z avec des valeurs extrêmes peuvent générer des échantillons de mauvaises qualité/incohérents.
- Limitation de ces effets : troncature pour contrôler les valeurs de z .

Hard Truncation :


$$z' = \begin{cases} t, & \text{si } z > t \\ -t, & \text{si } z < -t \\ z, & \text{sinon.} \end{cases}$$

- Problème : Réduction importante de la diversité des échantillons générés car elle exclut certaines régions de l'espace latent.

Soft Truncation :

$$z' = z \cdot \text{scale}$$

- Améliore la qualité en maintenant une diversité plus acceptable.




Troisième approche

Méthode (pendant et après training) :


- Deuxième approche avec :
 - Application de la soft-truncation pendant l'entraînement : training plus stable pour le discriminateur puisqu'il ne sera plus perturbé par des valeurs extrêmes.
 - Application de la soft-truncation pour la génération finale (ou pas, à tester).
- Valeur des vecteurs après application

$$z' = z \cdot \text{scale}$$

avec scale = 0.7.



Echantillons
acceptés



Echantillons
refusées

Troisième approche



Les résultats :

- **Précision:**
 - Chiffres beaucoup plus nets (0.55).
- **Recall:**
 - Perte énorme de diversité des classes (0.16)

Interprétations :

- **Précision:**
 - La soft truncation permet au générateur d'être guidé vers des régions de l'espace latent où il est performant. L'application du DRS par dessus permet une selection encore plus stricte sur la qualité.
- **Recall:**
 - Perte liée à la perte d'information liée à la soft truncation, et également au favoritisme du DRS pour les échantillons de meilleures qualités.

Diversité intra classe pour 1



0	9	5	3	7	9	5	0	7	0	3	7	0	6
9	4	2	4	7	5	1	7	4	7	8	9	0	7
3	5	0	6	7	2	1	9	1	3	2	7	3	9
1	1	9	1	9	6	9	7	3	9	6	3	0	6
9	3	6	1	2	0	9	5	1	3	0	8	5	7
7	5	4	1	9	5	0	4	2	3	7	1	9	7
1	0	9	5	0	0	8	9	7	2	7	6	4	1
7	7	6	5	2	7	0	5	6	4	3	3	1	7
3	9	9	8	4	0	9	8	5	6	9	9	9	7
8	2	3	1	0	2	1	0	9	5	7	1	3	2
8	9	9	9	3	9	3	3	9	3	0	1	7	1
0	7	2	4	4	3	3	1	6	0	1	0	7	3
5	9	8	1	0	4	0	3	1	9	5	0	6	7
9	3	9	6	3	2	2	2	2	1	6	1	7	5

Après DRS/soft truncation


8	3	6	5	7	0	0	0	5	2	3	4	7	5
8	6	0	8	1	1	4	4	3	8	6	2	6	3
7	7	3	4	0	5	2	3	1	4	2	8	4	9
1	3	4	4	7	0	1	2	2	6	5	5	5	6
1	0	3	4	0	0	6	9	1	8	2	9	2	3
0	2	7	9	1	9	2	7	7	6	8	7	1	1
3	2	3	2	0	6	6	7	7	9	8	4	2	5
9	6	4	0	2	9	5	0	3	9	1	6	7	9
1	4	2	3	8	8	1	1	3	6	8	0	5	1
0	1	0	8	3	8	3	5	9	0	0	6	7	6
8	4	0	0	2	1	5	0	2	5	2	3	0	3
0	9	5	5	6	5	7	3	7	9	5	7	9	0
6	0	2	3	9	8	8	5	6	8	1	4	9	4
5	1	4	6	8	4	7	5	0	4	9	1	6	4

Vanilla


Comment limiter cette perte de diversité ?

Hypothèses :

- Appliquer la soft truncation uniquement pendant le training.
- Perte de qualité probable car le générateur et le discriminateur sont entraînés sur un sous espace de l'espace des vecteurs latents.
- Limitation probable de diversité puisque lors de la génération, on explore l'espace dans sa totalité.



Echantillons
acceptés



Echantillons
refusées

Comment limiter cette perte de diversité ?



Les résultats :


- **Précision:**
 - Chiffres moins nets.
- **Recall:**
 - Réduction de la perte de diversité des classes.

Interprétations :


- **Précision:**
 - La soft truncation étant appliqué uniquement au training, générer les samples sans l'appliquer trouble le générateur et crée plus d'anomalies.
- **Recall:**
 - La prise en compte de tout l'espace pour la génération des vecteurs latents z a permis d'obtenir plus de diversité.

Diversité intra classe pour 1





Après DRS/soft truncation (training)



Vanilla

Quatrième approche

Méthode (pendant et après training) :

- Rappel : $\frac{D(x)}{1 - D(x)} = \frac{p_{\text{data}}}{p_g}$ représente la crédibilité relative de l'échantillon.

- Idée : Ajuster scale en fonction de ce ratio:


- Échantillons crédibles (ratio élevé) :
 - Troncation peu sévère, conserve diversité.

- Échantillons moins crédibles (ratio faible) :
 - Troncation plus sévère, améliorant la qualité.


$$\text{scale} = \frac{D(x)}{1 - D(x) + \epsilon}, \quad \epsilon > 0$$

$$z' = z \cdot \text{scale}$$

- On clamp scale entre 0.5 et 1.2 pour empêcher des modifications excessives sur z (moins on clamp, plus l'on aura de la diversité).



Echantillons
acceptés



Echantillons
refusées

Quatrième approche



Les résultats :

- **Précision:**
 - Chiffres moins nets qu'avec la soft truncation.
- **Recall:**
 - Nette amélioration de la diversité.

Interprétations :

- **Précision:**
 - On garde tout de même des valeurs extrêmes : réduit obligatoirement la qualité par rapport à la soft truncation.
- **Recall:**
 - Troncation adaptative permet de prendre en compte énormément de caractéristiques du vecteur latent.

Diversité intra classe pour 1



6	5	6	2	3	2	3	6	9	8	1	0	2	3
3	9	8	2	3	9	2	8	6	0	6	6	2	9
3	9	7	9	5	0	7	8	6	5	7	0	6	9
0	7	0	5	5	7	9	2	1	0	9	2	4	5
2	0	9	9	0	6	9	4	6	0	3	7	3	3
9	1	9	6	1	4	9	7	4	2	9	2	4	8
6	2	5	7	3	7	6	9	9	9	7	5	6	7
2	3	2	9	3	4	3	7	6	4	5	0	3	5
2	7	4	8	5	9	9	7	9	8	4	7	7	1
6	9	9	9	7	5	6	4	2	8	5	1	9	3
7	9	6	1	2	8	4	6	6	9	4	2	7	2
9	1	9	0	4	6	0	2	5	7	4	2	0	7
2	6	9	4	2	7	0	5	6	7	7	8	1	3
3	1	9	7	1	2	9	5	9	2	9	3	3	4

Après DRS/adaptative truncation (training)

8	3	6	5	7	0	0	0	4	2	3	4	7	5
8	6	0	8	1	1	4	4	3	8	6	2	6	3
7	7	3	4	0	5	2	3	1	4	2	8	4	9
1	3	4	4	7	0	1	2	2	6	5	5	5	6
1	0	3	4	0	0	6	9	1	8	1	9	2	3
0	2	7	9	1	9	2	7	7	6	8	7	1	1
3	2	3	2	0	6	6	7	7	9	8	4	2	5
9	6	4	0	2	9	8	0	3	9	1	6	7	9
1	4	3	3	8	8	1	1	3	6	8	0	5	1
0	1	0	8	3	8	3	5	9	0	0	6	7	6
8	4	0	0	2	1	5	0	2	5	2	3	0	3
0	9	5	5	6	5	7	3	7	9	5	7	9	0
6	0	2	3	9	8	8	5	6	8	1	4	9	4
5	1	4	6	8	4	7	3	0	4	4	1	6	4

Vanilla

III) CONCLUSION ET AMÉLIORATIONS POSSIBLES DU DRS

Limites du DRS :

- Amélioration limitée de la qualité : dépend énormément du discriminateur
- Rejet excessif en cas de distribution complexe : indépendance des samples générés par la distribution latente.

Résumé des Méthodes :

- DRS : Légère amélioration qualité/diversité
- DRS/Soft truncation : Renforce énormément la qualité mais diversité limitée.
- DRS/Adaptive truncation : Compromis entre qualité/diversité.

Améliorations possibles :

- Inclure une dépendance entre les samples générés par la distribution latente : Trouver les zones où la distribution latente $\sim$ target distribution.
 - --> Metropolis Hastings Algorithm : Utilisation des chaînes de Markov.